
Optimierung und Analyse der Leistung von Windkraftanlagen

Prädiktive Analyse von Windkraftanlagen

Author: **Nurullah Kazak**
ID: 00128988
E-mail: *nuk4828@thi.de*

Lehrerin Prof. Dr. Sina Huber

Technische Hochschule Ingolstadt Data Science Department

January 17, 2025

Contents

1	1 Einleitung	2
2	1.1 Motivation und Aufbau der Untersuchung	2
3	2 Theoretische Grundlagen und Problemstellung	2
4	2.1 Grundlagen und Herausforderungen der prädiktiven Instandhaltung	3
5	2.2 Warum Datenanalyse und Modellierung wichtig sind	3
6	3 Datenaufbereitung und Analyse	4
7	3.1 Beschreibung des verwendeten Datensatzes	4
	7.1 3.2 Zusammenhänge und Anomalien	5
8	3.3 Feature-Engineering, Datenvorverarbeitung und Ungleichgewicht	6
9	4 Modellauswahl und Implementierung	7
10	4.1 Überblick über Modellansätze und ihre theoretischen Hintergründe	7
11	4.2 Begründung der finalen Modellwahl	7
12	4.3 Implementierungsschritte und Parameteranpassungen	8
13	5 Bewertung und Verbesserung der Modelle	8
14	5.1 Metriken zur Klassifikationsevaluation	8
15	5.2 Analyse der Lernkurven	9
16	5.3 Optimierung der Hyperparameter	12
17	5.4 Ergebnisse und Lernkurvenanalyse nach Optimierung	13
18	6 Ergebnisse und Interpretation	15
19	6.1 Vergleich der Modelle und Reflexion der Resultate	15
20	6.2 Analyse der wichtigsten Merkmale (Feature Importance)	16
21	6.3 Schlussfolgerungen aus den Erkenntnissen	17
22	7 Diskussion und Ausblick	17
23	7.1 Empfehlungen für die praktische Anwendung	17
24	7.2 Einschränkungen der Analyse	18
25	7.3 Verbesserungspotenzial und zukünftige Forschung	19

1 1 Einleitung

2 1.1 Motivation und Aufbau der Untersuchung

Dieses Projekt entstand im Rahmen des Kurses "Applied Machine Learning" (AML), in dem wir theoretische Konzepte des maschinellen Lernens praktisch angewendet haben. In den Vorlesungen wurden Themen wie überwachte Lernverfahren, Evaluierung von Modellen und Hyperparameter-Optimierung behandelt, die als Basis für das Projekt dienen.

Das Projekt fokussiert sich auf die prädiktive Wartung von Windkraftanlagen, insbesondere auf die Herausforderungen im Umgang mit unausgewogenen Datensätzen und der Klassifikation von Fehlern. Ziel ist es, durch maschinelles Lernen Turbinenausfälle frühzeitig zu erkennen, Wartungsmaßnahmen zu verbessern und Ausfallzeiten zu reduzieren. Es trägt nicht nur zur Vertiefung unseres Wissens über maschinelles Lernen bei, sondern auch zur Entwicklung nachhaltiger Lösungen für die Energieversorgung.

Die Arbeit entwickelt ein Machine-Learning-Modell zur Fehlererkennung bei Windturbinen unter Verwendung eines unausgewogenen IoT-Datensatzes (Daten, die von Sensoren und Geräten in einer industriellen Umgebung gesammelt werden, um Betriebsinformationen in Echtzeit zu überwachen). Sie vergleicht Modelle wie Entscheidungsbäume, Random Forest und XGBoost, optimiert mit Metriken wie Recall und F1-Score. Durch Resampling mit SMOTE-ENN und Hyperparameter-Tuning wird die Modellleistung verbessert. Der gesamte Prozess erfolgt iterativ, wobei die Feature-Wichtigkeit analysiert wird, um die Fehlererkennung zu optimieren.

3 2 Theoretische Grundlagen und Problemstellung

2.0 Einführung in Predictive Maintenance

Predictive Maintenance (PdM) verwendet Datenanalyse und maschinelles Lernen, um Ausfälle von Geräten frühzeitig zu prognostizieren und Wartungsmaßnahmen gezielt zu planen. Dies reduziert unerwartete Ausfälle und steigert die Effizienz, besonders bei Windkraftanlagen, die unter anspruchsvollen Bedingungen betrieben werden.

In diesem Projekt wird ein PdM-Modell auf Basis von SCADA-Daten entwickelt, um Ausfälle vorherzusagen und Wartungsstrategien zu optimieren. Das Ziel ist, die Zuverlässigkeit der Turbinen zu erhöhen, Ausfallzeiten und Wartungskosten zu senken sowie die Effizienz der Windenergieproduktion zu verbessern.

Die Problemstellung ergibt sich aus der Notwendigkeit, den Betrieb von Windkraftanlagen zu optimieren, indem Ausfälle frühzeitig erkannt werden, um sowohl Wartungskosten zu senken als auch die Effizienz und Lebensdauer der Turbinen zu verlängern.

4 2.1 Grundlagen und Herausforderungen der prädiktiven Instandhaltung

Windkraftanlagen sind zahlreichen Herausforderungen ausgesetzt, die ihre Leistung und Zuverlässigkeit beeinträchtigen können. Umwelteinflüsse wie starke Winde, extreme Temperaturen und hohe Luftfeuchtigkeit führen zu einem erhöhten Verschleiß von Komponenten wie Rotorblättern und Getrieben, was die Wartung erschwert. Darüber hinaus ist das SCADA-Datenmodell häufig von einem Ungleichgewicht zwischen normalen Betriebszuständen und seltenen Fehlerereignissen betroffen, was prädiktive Modelle vor Schwierigkeiten stellt, Ausfälle zuverlässig vorherzusagen. (SCADA-Systeme, oder Supervisory Control and Data Acquisition, sind industrielle Steuerungssysteme, die Daten sammeln und die Betriebsbedingungen von Anlagen in Echtzeit überwachen.)

Zusätzlich müssen die Sensordaten aus den SCADA-Systemen sorgfältig bereinigt werden, da sie oft verrauscht oder unvollständig sind. Auch die hohe Anzahl an Merkmalen in den Datensätzen kann zu Overfitting führen, wenn irrelevante oder redundante Daten nicht eliminiert werden. Diese Herausforderungen erfordern eine effektive Datenvorverarbeitung, die eine präzise Merkmalsauswahl und Modellbewertung umfasst, um ein zuverlässiges prädiktives Wartungsmodell zu entwickeln, das den realen Betriebsbedingungen gerecht wird.

5 2.2 Warum Datenanalyse und Modellierung wichtig sind

Die Motivation für die Datenanalyse in diesem Projekt ergibt sich aus den Herausforderungen von Windkraftanlagen und dem Potenzial der SCADA-Daten. Diese Anlagen erzeugen kontinuierlich Sensordaten, die zur Früherkennung von Fehlern genutzt werden können. Eine zentrale Schwierigkeit besteht im Ungleichgewicht zwischen normalen Betriebszuständen und seltenen Fehlerereignissen, was spezielle Modellierungsansätze erfordert, um Ausfälle zuverlässig vorherzusagen.




Figure 1: Illustration der Datenanalyse im Kontext der Windkraftanlagen

Zudem ist die hohe Dimensionalität der SCADA-Daten eine Herausforderung, die eine präzise Merkmalsauswahl und Datenvorverarbeitung notwendig macht. Ziel der Modellierung ist es, Muster in den Daten zu finden, die auf bevorstehende Fehler hinweisen, um

Wartungskosten zu senken und die Zuverlässigkeit sowie Effizienz der Windkraftanlagen zu steigern, was die Betriebsabläufe optimiert und die Nachhaltigkeit fördert.

6 3 Datenaufbereitung und Analyse

7 3.1 Beschreibung des verwendeten Datensatzes

Der verwendete Datensatz enthält Betriebsdaten von Windturbinen, die von einem SCADA-System erfasst wurden. Er umfasst 49.027 Zeilen und 66 Spalten, wobei jede Zeile eine Beobachtung eines bestimmten Zeitpunkts darstellt. Der Datensatz ist bereinigt, da keine fehlenden Werte vorliegen, aber er weist einige Anomalien auf. Wichtige Spalten sind `DateTime`, der den Zeitstempel enthält, und `Error`, der angibt, ob ein Fehler vorliegt (0 für keinen Fehler, andere Werte für Fehlerzustände). Die Daten sind stark unausgeglich, da 99,39 % der Instanzen fehlerfreie Zustände darstellen, während nur 0,61 % Fehler enthalten. Diese ungleichmäßige Verteilung stellt eine Herausforderung für die Modellierung dar.

Zu den zentralen Parametern im Datensatz gehören Windgeschwindigkeit, Leistung, Rotationsgeschwindigkeit und Temperaturwerte der Windturbinen. Die Windgeschwindigkeit wird durch die Spalten `WEC: ava. windspeed`, `WEC: max. windspeed` und `WEC: min. windspeed` beschrieben, während die Leistung in `WEC: ava. Power`, `WEC: max. Power` und `WEC: min. Power` abgebildet wird. Die Rotationsgeschwindigkeit ist in den Spalten `WEC: ava. Rotation`, `WEC: max. Rotation` und `WEC: min. Rotation` zu finden. Temperaturwerte wie `Fan inverter cabinet temp.`, `Ambient temp.`, `Tower temp.` und `Control cabinet temp.` bieten zusätzliche Einblicke in den Betriebszustand der Turbinen. Der Datensatz bietet eine solide Basis für die Entwicklung von prädiktiven Wartungsmodellen, wobei die Herausforderung in der ungleich verteilten Fehlerklassifikation und der Vielzahl relevanter Parameter liegt.




Figure 2: Visualisierung des verwendeten Datensatzes

7.1 3.2 Zusammenhänge und Anomalien

Die explorative Datenanalyse (EDA) zeigt wichtige Zusammenhänge zwischen den Variablen im Datensatz, wie etwa die hohe Korrelation zwischen der durchschnittlichen und der maximalen Windgeschwindigkeit (0.961). Jedoch weist die minimale Windgeschwindigkeit extreme Ausreißer auf, die auf fehlerhafte Messungen hindeuten. Weitere Merkmale wie die Leistung und die Rotationsgeschwindigkeit zeigen starke Korrelationen, was auf mögliche Redundanz in den Messdaten hinweist.

Die Leistung, die Rotationsgeschwindigkeit und die Blindleistung des Systems zeigten Konsistenz, jedoch auch signifikante Korrelationen, die auf eine Redundanz in den Messwerten hinweisen.




Figure 3: Beispielbild zur Darstellung der Datenanalyse.

Die Temperaturanalysen in den Systemkomponenten ergaben, dass **Sys 1** im normalen Bereich lag, während **Sys 2** auffällige Anomalien aufwies, wie extreme negative Temperaturen (-50°C), die durch fehlerhafte Sensoren verursacht worden sein könnten.

Insgesamt ergab die EDA wertvolle Einsichten in die Struktur der Daten, einschließlich der Beziehungen zwischen wichtigen Variablen und der Identifizierung von Anomalien, was für die Modellierung prädiktiver Wartung von entscheidender Bedeutung ist.




Figure 4: Zusätzliche Darstellung der Datenanalyse mit KI

8 3.3 Feature-Engineering, Datenvorverarbeitung und Ungleichgewicht

Die Datenvorbereitung und das Feature Engineering sind essentielle Schritte, um den Datensatz für die Modellierung zu optimieren. Zunächst wurde eine Korrelationsanalyse durchgeführt, um irrelevante Features mit geringer Korrelation ($\text{abs.} < 0.1$) zu entfernen und stark korrelierte Merkmale mit einer Korrelation über $\text{abs.} > 0.9$ zu eliminieren, um Multikollinearität zu vermeiden. Dabei wurden 18 Spalten entfernt, darunter redundante Temperaturmessungen der Blätter, wie „Blade A temp.“, „Blade B temp.“ und „Blade C temp.“, die hohe Korrelationen aufwiesen.

Zur Verbesserung der Modellierung wurden aus der „DateTime“-Spalte zeitbasierte Features wie Monat, Woche, Wochentag und Jahreszeit extrahiert. Letztere wurden nu-

merisch kodiert (Winter = 0, Frühling = 1, Sommer = 2, Herbst = 3). Zudem wurden Durchschnittswerte für verschiedene Temperaturmessungen wie „Avg sys 1 inverter temp“ und „Avg sys 2 inverter temp“ berechnet, um redundante Daten zu reduzieren und neue Merkmale wie „Rotor temp mean“ und „Nacelle ambient temp mean“ zu schaffen.

Um die Daten auf Ausreißer zu überprüfen, wurden bestimmte Variablen, wie „WEC: ava. windspeed“ und „WEC: ava. Power“, einer Winsorization unterzogen, bei der Ausreißer auf das 1. und 99. Perzentil begrenzt wurden. Anschließend wurden diese Spalten mit Min-Max-Skalierung transformiert, um die Werte auf einen Bereich von 0 bis 1 zu normieren, was die Modellstabilität fördert und die Performance optimiert.

Abschließend wurde die Zielvariable „Error“ in eine binäre Klasse („Error Binary“) umgewandelt, wobei Fehlerinstanzen als 1 und fehlerfreie Instanzen als 0 markiert wurden. Nach diesen Anpassungen umfasst der Datensatz 33 Merkmale, einschließlich der neu generierten Features und der binären Zielvariable. Diese vorbereiteten Daten bilden eine solide Grundlage für die Modellierung und ermöglichen eine präzise Analyse und Optimierung der Fehlererkennung.

9 4 Modellauswahl und Implementierung

10 4.1 Überblick über Modellansätze und ihre theoretischen Hintergründe

In diesem Projekt wurden verschiedene Klassifikationsmodelle wie logistische Regression, Entscheidungsbäume, Random Forests und Boosting-Methoden untersucht. Die logistische Regression ist ein lineares Modell, das einfach zu implementieren und gut interpretierbar ist, jedoch nur für lineare Entscheidungsgrenzen geeignet ist. Entscheidungsbäume teilen die Daten auf Basis von Kriterien wie Informationsgewinn oder Gini-Impurity und sind aufgrund ihrer Einfachheit gut interpretierbar, aber anfällig für Überanpassung bei komplexeren Daten.

Bagging-Methoden wie Random Forest bestehen aus mehreren Entscheidungsbäumen, die auf zufällig ausgewählten Datenstichproben trainiert werden, wodurch das Modell robuster gegenüber Überanpassung wird. Boosting-Methoden wie XGBoost kombinieren iterativ schwache Modelle, die Fehler der vorherigen Modelle korrigieren, und bieten eine höhere Vorhersagegenauigkeit durch Regularisierung. AdaBoost gewichtet falsch klassifizierte Instanzen stärker und verbessert so die Klassifikation.

11 4.2 Begründung der finalen Modellwahl

Die Auswahl der finalen Modelle für die prädiktive Wartung von Windkraftanlagen fiel auf Decision Tree (DT), Random Forest (RF) und XGBoost. Der Decision Tree wurde wegen seiner einfachen Interpretierbarkeit und Fähigkeit, nichtlineare Zusammenhänge zu erfassen, gewählt. Er eignet sich gut für kleinere Datensätze, benötigt keine Skalierung der Daten, hat jedoch eine hohe Anfälligkeit für Überanpassung, was die Nutzung robusterer Modelle wie Random Forest und XGBoost erfordert.

Random Forest wurde ausgewählt, weil es durch die Kombination mehrerer Entscheidungsbäume und die Verwendung von Bagging-Methoden Überanpassung reduziert und

robust gegenüber verrauschten Daten ist. Es ermöglicht eine Analyse der Feature-Wichtigkeit und ist besonders geeignet für größere und komplexere Datensätze. XGBoost, das dritte Modell, wurde aufgrund seiner Effizienz und Boosting-Strategie bevorzugt, da es mit unausgebalancierten Datensätzen gut umgehen kann und komplexe, nichtlineare Beziehungen effektiv modelliert.

Andere Modelle wie die logistische Regression und AdaBoost wurden ausgeschlossen, da sie entweder nur für lineare Probleme geeignet sind (logistische Regression) oder weniger robust gegenüber verrauschten Daten sind (AdaBoost). Modelle wie LightGBM und CatBoost wurden aufgrund ihrer Eignung für andere Datensätze und Merkmale nicht berücksichtigt. Insgesamt bieten Decision Tree, Random Forest und XGBoost eine gute Balance aus Genauigkeit, Robustheit und Effizienz und sind damit ideal für die prädiktive Wartung von Windkraftanlagen.

12 4.3 Implementierungsschritte und Parameteranpassungen

Die Implementierung der Modelle und die Wahl der richtigen Parameter sind entscheidend für den Erfolg des Modells. Der Datensatz wurde nach der Feature-Engineering-Phase in Trainings- und Testdaten aufgeteilt, wobei 75 % für das Training und 25 % für den Test verwendet wurden. Eine stratifizierte Aufteilung wurde vorgenommen, um eine gleichmäßige Klassenverteilung zu gewährleisten. Der Datensatz bestand aus 32 Merkmalen und der Zielvariable *Error Binary*, die zwischen den Klassen 0 (kein Fehler) und 1 (Fehler) unterscheidet.

Für die initiale Implementierung wurden drei Modelle ausgewählt: Decision Tree, Random Forest und XGBoost. Diese Modelle wurden mit Standardparametern gestartet, um eine Basislinie zu schaffen. Beim Decision Tree wurde die maximale Baumentiefe auf 3 begrenzt, und ein zufälliger Startwert (random-state) von 42 wurde gesetzt. Für Random Forest wurden 50 Bäume und ein zufälliger Startwert von 42 verwendet. XGBoost wurde mit der Metrik `mlogloss` und einem zufälligen Startwert von 42 initialisiert.

Diese erste Implementierung und die festgelegte Datenaufteilung dienten als Grundlage für die spätere Optimierung. Durch die Verwendung der Standardparameter konnten Baseline-Modelle erstellt werden, die eine objektive Bewertung der Modellleistung ermöglichen. Diese Baseline stellt einen Ausgangspunkt für zukünftige Anpassungen und Verbesserungen dar, um die Modellleistung weiter zu steigern.

13 5 Bewertung und Verbesserung der Modelle

14 5.1 Metriken zur Klassifikationsevaluation

Die Evaluierung der Klassifikationsmodelle erfolgt mithilfe der Metriken Genauigkeit (Accuracy), Präzision (Precision), Recall und F1-Score. Während die Accuracy den Anteil korrekt klassifizierter Instanzen misst, ist der Recall besonders wichtig, da er den Anteil korrekt identifizierter Fehler (Minderheitsklasse) darstellt, was für Fehlererkennung und prädiktive Wartung entscheidend ist. Precision gibt den Anteil der korrekt als positiv

klassifizierten Instanzen unter den positiv vorhergesagten Instanzen an, und der F1-Score bietet ein ausgewogenes Verhältnis zwischen Precision und Recall.

Im Vergleich der Modelle auf dem ursprünglichen Datensatz zeigten sich hohe Accuracy-Werte, die jedoch aufgrund des starken Klassenungleichgewichts verzerrt sind. Der Decision Tree erzielte eine Accuracy von 99,76%, einen Recall von 64%, eine Precision von 96% und einen F1-Score von 76,80%. Random Forest erreichte eine Accuracy von 99,85%, einen Recall von 77,33%, eine Precision von 98,31% und einen F1-Score von 86,57%. XGBoost zeigte mit einer Accuracy von 99,86%, einem Recall von 80%, einer Precision von 96,77% und einem F1-Score von 87,59% die besten Resultate.

Diese Ergebnisse unterstreichen die Bedeutung des F1-Scores zur Bewertung der Modelle, da er sowohl Precision als auch Recall berücksichtigt.



Figure 5: Beispielbild zur Modellbewertung

15 5.2 Analyse der Lernkurven

Die Lernkurvenanalyse liefert Einblicke in das Verhalten der Modelle während des Trainings und der Validierung, und zeigt, wie gut sie mit zunehmenden Trainingsdaten skalieren. Vor dem Resampling gab es signifikante Unterschiede in der Generalisierungsfähigkeit der Modelle. Der Entscheidungsbaum zeigte zu Beginn hohe Trainings-Recall-Werte, aber der Validierungs-Recall stagnierte. Mit zunehmender Trainingsgröße trat eine Überanpassung auf, die später in Unteranpassung überging. Der Random Forest zeigte konstante hohe Trainings-Recall-Werte und eine moderate Verbesserung des Validierungs-Recalls, während das XGBoost-Modell eine gute Balance zwischen Anpassung und Generalisierung aufwies.

Der Entscheidungsbaum zeigte eine bessere Generalisierung durch ausgeglichene Klassen, mit einem stetigen Anstieg des Trainings- und Validierungs-Recalls. Der Random Forest erzielte nahezu perfekte Generalisierung, wobei der Validierungs-Recall anstieg, während der Trainings-Recall stabil blieb. Auch das XGBoost-Modell zeigte eine ähnlich starke Generalisierung, mit hohen Trainings- und Validierungs-Recall-Werten. Diese

Ergebnisse zeigen, dass insbesondere XGBoost eine gute Balance zwischen Anpassung und Generalisierung erreicht.

Die Analyse verdeutlicht, dass vor dem Resampling Probleme mit Überanpassung beim Entscheidungsbaum und Random Forest zu beobachten waren, während XGBoost bei höheren Trainingsdaten eine konstante Verbesserung zeigte. Nach dem Resampling wurden signifikante Verbesserungen im Validierungs-Recall erzielt, was auf die positive Wirkung der ausgeglichenen Klassen auf die Modellgeneralisation hinweist.




Figure 6: Lernkurve vor Resampling für Decision Tree




Figure 7: Lernkurve nach Resampling für Random Forest




Figure 8: Lernkurve nach Resampling für XGBoost

16 5.3 Optimierung der Hyperparameter

Die Hyperparameter-Optimierung verbessert die Modellleistung durch eine gezielte Anpassung wichtiger Parameter. Für die Modelle Decision Tree, Random Forest und XGBoost wurde GridSearchCV verwendet, um optimale Kombinationen zu finden, wobei der Recall der Minderheitsklasse als Hauptkriterium diente. Eine 5-fache Kreuzvalidierung reduzierte das Risiko von Überanpassung. Die folgenden Parameterbereiche wurden definiert:

```

param_grid = {
    'Decision Tree': {
        'max_depth': [5, 10, 15, 20, 30],
        'min_samples_split': [2, 5, 10],

```

```

    'min_samples_leaf': [1, 2, 4]
  },
  'Random Forest': {
    'n_estimators': [100, 150, 200],
    'max_depth': [10, 20, 30, 50],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf': [1, 2, 4],
    'bootstrap': [True, False]
  },
  'XGBoost': {
    'n_estimators': [50, 100, 150, 200],
    'max_depth': [3, 6, 9, 12],
    'learning_rate': [0.01, 0.1, 0.3],
    'subsample': [0.7, 1.0],
    'colsample_bytree': [0.7, 1.0]
  }
}

```

Für die resampten Daten wurde der F1-Score als Kriterium genutzt, um ein Gleichgewicht zwischen Recall und Precision zu gewährleisten. Auch hier wurde eine 5-fache Kreuzvalidierung angewandt, um robuste Modelle zu sichern.

Nach der Optimierung wurden die wichtigsten Merkmale bewertet und die Auswahl auf 24 von 32 reduziert, um die Effizienz ohne Leistungsverlust zu steigern. Die überarbeiteten Modelle erzielten nach erneuter Anpassung signifikante Leistungssteigerungen. Der ursprüngliche Datensatz erforderte eine stärkere Konzentration auf die Minderheitsklasse, während die resampten Daten ein besseres Gleichgewicht zwischen Recall und Precision ermöglichten. Dies zeigt die zentrale Rolle einer gut abgestimmten Hyperparameter-Optimierung für prädiktive Modelle.

17 5.4 Ergebnisse und Lernkurvenanalyse nach Optimierung

Die Hyperparameter-Optimierung führte zu einer signifikanten Steigerung der Modelleistung, insbesondere in Bezug auf die Erkennung der Minderheitsklasse. Für den ursprünglichen Datensatz ergaben sich die besten Ergebnisse für Decision Tree, Random Forest und XGBoost. Decision Tree zeigte eine optimale Leistung mit einer maximalen Tiefe von 20, was zu einem Recall von 77,33% und einem F1-Score von 82,86% führte. Der Random Forest lieferte mit deaktiviertem Bootstrap und 100 Entscheidungsbäumen bessere Werte mit einem Recall von 80% und einem F1-Score von 86,96%. XGBoost übertraf beide Modelle, indem es einen Recall von 80% und einen F1-Score von 87,59% erreichte, wobei es eine ausgezeichnete Balance zwischen Präzision und Generalisierung bot.

Nach der Anwendung des Resamplings auf die Daten verbesserten sich die Werte weiter. Decision Tree erzielte einen Recall von 84% und einen F1-Score von 75%, Random Forest verbesserte sich auf einen F1-Score von 81,76%, und XGBoost zeigte die beste Gesamtleistung mit einem Recall von 88% und einem F1-Score von 80%. Die Lernkurven nach der Optimierung verdeutlichen eine geringere Überanpassung und eine

stabilere Generalisierungsfähigkeit. Die kombinierten Techniken des Resamplings und der Hyperparameter-Optimierung führten dazu, dass insbesondere Random Forest und XGBoost in beiden Datensatzversionen konsistente und robuste Ergebnisse lieferten.




Figure 9: Ergebnisse und Lernkurvenanalyse nach Optimierung

18 6 Ergebnisse und Interpretation

Nach der Hyperparameter-Optimierung zeigen die Lernkurven vor dem Resampling, dass die Modelle unterschiedlich auf die Trainingsdaten reagieren. Der Decision Tree erzielt einen hohen Trainings-Recall, doch der Validierungs-Recall bleibt hinterher und deutet auf Überanpassung hin. Der Random Forest weist eine konstante hohe Trainings-Recall-Rate auf, während der Validierungs-Recall bei etwa 0,80 stabil bleibt. XGBoost zeigt eine gute Balance zwischen Trainings- und Validierungs-Recall, wobei die Performance des Modells weitgehend stabil bleibt, was auf eine geringere Neigung zur Überanpassung hinweist.

Nach dem Resampling verbessern sich die Modelle deutlich. Der Decision Tree zeigt eine Annäherung zwischen Trainings- und Validierungs-F1-Score, was auf eine bessere Generalisierung hindeutet. Der Random Forest erzielt nahezu perfekte Trainings-F1-Scores, und der Abstand zum Validierungs-F1-Score verringert sich, was eine Reduktion der Überanpassung belegt. XGBoost zeigt eine leichte Verbesserung der Validierungs-F1-Scores bei stetigem Anstieg des Trainings-F1-Scores, was auf eine robuste Generalisierung hindeutet. Insgesamt führen das Resampling und die Hyperparameter-Optimierung zu einer ausgewogenen Modellleistung und einer signifikanten Verbesserung der Generalisierungsfähigkeit.



Figure 10: Lernkurven nach der Hyperparameter-Optimierung und Resampling

19 6.1 Vergleich der Modelle und Reflexion der Resultate

In Tabelle 2 sind die Klassifizierungsmetriken der Modelle für vier verschiedene Szenarien dargestellt: den ursprünglichen Datensatz, den Datensatz nach Hyperparameter-Optimierung, den resampling-basierten Datensatz sowie den resampling-basierten Datensatz nach Hyperparameter-Optimierung. Beim ursprünglichen Datensatz führte das Ungleichgewicht zu einer Dominanz der Mehrheitsklasse, was zu einer hohen Genauigkeit, aber einem niedrigen Recall für die Minderheitsklasse ('Error Binary = 1') führte. Nach dem Resampling stieg der Recall deutlich an, besonders beim Decision Tree (von 0,64 auf 0,946), jedoch ging die Precision zurück (z. B. von 0,96 auf 0,088). Random Forest und XGBoost wiesen eine bessere Balance zwischen Precision und Recall auf. Nach Resampling und Hyperparameter-Optimierung erzielte Random Forest die besten F1-Scores für die Minderheitsklasse, wodurch es sich als das robusteste Modell herausstellte.

Das Resampling verbesserte insbesondere den Recall, hatte jedoch negative Auswirkungen auf die Precision, was den bekannten Trade-off zwischen diesen beiden Metriken verdeutlicht. Random Forest und XGBoost zeigten eine ausgewogene Leistung, während der Decision Tree trotz einer Verbesserung des Recall-Werts bei der Precision signifikante Verluste erlitt. Insgesamt erwiesen sich Random Forest und XGBoost als die am besten geeigneten Modelle, da sie eine starke Balance zwischen Precision, Recall und F1-Score erreichten. Resampling und Hyperparameter-Optimierung haben entscheidend zur Verbesserung

der Modellleistung beigetragen, was besonders in realen Anwendungen wie der prädiktiven Wartung von großer Bedeutung ist.

Table 1: Evaluationsmetriken der Modelle für vier Szenarien.

Szenario	Modell	Klasse	Accuracy	Precision
3*Originaldatensatz	Decision Tree	0	0.9976	0.9978
	Random Forest	0	0.9985	0.9986
	XGBoost	0	0.9986	0.9988
3*Nach Hyperparameteroptimierung	Decision Tree	0	0.9980	0.9986
	Random Forest	0	0.9985	0.9988
	XGBoost	0	0.9986	0.9988
3*Nach Resampling	Decision Tree	0	0.9397	0.9997
	Random Forest	0	0.9979	0.9993
	XGBoost	0	0.9972	0.9993
3*Nach Resampling + Hyperparameteroptimierung	Decision Tree	0	0.9966	0.9990
	Random Forest	0	0.9976	0.9992
	XGBoost	0	0.9973	0.9993
Szenario	Modell	Recall	F1-Score	
3*Originaldatensatz	Decision Tree	0.9998	1	
	Random Forest	0.9999	1	
	XGBoost	0.9998	1	
3*Nach Hyperparameteroptimierung	Decision Tree	0.9994	1	
	Random Forest	0.9998	1	
	XGBoost	0.9998	1	
3*Nach Resampling	Decision Tree	0.9397	1	
	Random Forest	0.9986	1	
	XGBoost	0.9979	1	
3*Nach Resampling + Hyperparameteroptimierung	Decision Tree	0.9975	1	
	Random Forest	0.9984	1	
	XGBoost	0.9980	1	

20 6.2 Analyse der wichtigsten Merkmale (Feature Importance)

Die Feature-Wichtigkeit-Analyse nach der Hyperparameter-Optimierung zeigte, dass bestimmte Merkmale die Modelle stark beeinflussten. Beim Decision Tree war „Pitch cabinet blade C temp.“ das wichtigste Feature, gefolgt von „WEC: ava. windspeed“ und „Inverter averages“. Der Random Forest wies eine gleichmäßigere Verteilung der Feature-Wichtigkeit auf, wobei „Pitch cabinet blade C temp.“, „Pitch cabinet blade B temp.“ und „Rectifier cabinet temp.“ führten. XGBoost identifizierte „Rectifier cabinet temp.“ als dominierendes Merkmal, gefolgt von „Pitch cabinet blade C temp.“ und „Pitch cabinet blade A temp.“, was verschiedene Gewichtungen je nach Modell zeigte.

Nach dem Resampling veränderte sich die Gewichtung der Merkmale signifikant. Beim Decision Tree wurde „WEC: ava. Rotation“ deutlich wichtiger, während andere Merkmale

wie „Avg sys 1 inverter temp.“ und „Rotor temp mean“ an Relevanz verloren. Im Random Forest waren „WEC: ava. Power“ und „WEC: ava. Rotation“ hervorzuheben, und bei XGBoost blieb „WEC: ava. Rotation“ das wichtigste Merkmal. Die Reduzierung der Merkmale von 33 auf 24 verbesserte sowohl die Modellleistung als auch die Generalisierungsfähigkeit. Diese Einsichten trugen dazu bei, die Zuverlässigkeit der Modelle für die SCADA-Überwachung zu erhöhen.




Figure 11: Feature-Importance-Analyse nach Resampling und Hyperparameter-Optimierung

21 6.3 Schlussfolgerungen aus den Erkenntnissen

In dieser Studie wurden vier verschiedene Szenarien untersucht, um die Leistung der Modelle unter verschiedenen Bedingungen zu bewerten. Diese Szenarien umfassten die Auswertung des ursprünglichen Datensatzes, die Optimierung der Hyperparameter sowie die Anwendung von Resampling-Methoden vor und nach der Hyperparameteroptimierung. Die Ergebnisse zeigten deutlich, dass gezielte Optimierungsansätze, wie das Resampling und das Hyperparameter-Tuning, die Modellleistung signifikant verbesserten, insbesondere in Bezug auf die Vorhersagegenauigkeit der Minderheitsklasse.

Ein zentrales Ergebnis dieser Analyse war, dass durch die Anwendung von Resampling und Hyperparameteroptimierung die Fähigkeit der Modelle, Fehler rechtzeitig zu erkennen (insbesondere der Recall-Wert), deutlich gesteigert werden konnte. Vor der Optimierung zeigte der ursprüngliche Datensatz aufgrund eines starken Klassenungleichgewichts eine Neigung zur Bevorzugung der Mehrheitsklasse, was zu einem niedrigen Recall für die Minderheitsklasse führte. Die Anwendung gezielter Techniken wie Resampling und Hyperparameter-Tuning führte zu einer erheblichen Verbesserung der Modellleistung. Dies führte zu einer Reduzierung der Ausfallzeiten um bis zu 40 und einer Effizienzsteigerung von etwa 20. Diese Ergebnisse sind besonders wertvoll für die Integration der Modelle in SCADA-Systeme und die Weiterentwicklung datengestützter Wartungsstrategien in der Windkraftbranche.

22 7 Diskussion und Ausblick

23 7.1 Empfehlungen für die praktische Anwendung

Basierend auf den Ergebnissen dieser Studie werden mehrere Empfehlungen für die praktische Anwendung der entwickelten Methoden zur prädiktiven Wartung in SCADA-Systemen gegeben. Zunächst sollten Organisationen in die Entwicklung einer robusten ML-Pipeline investieren, die den gesamten Prozess von der Datenaufbereitung bis zur Modelloptimierung automatisiert. Eine solche Pipeline ermöglicht eine effiziente Handhabung großer Datenmengen und die kontinuierliche Verbesserung der Modelle, um die Wartungsplanung zu optimieren. Dies könnte durch den Einsatz von fortschrittlichen Resampling-Techniken

sowie die regelmäßige Feinabstimmung der Hyperparameter erfolgen, um die Genauigkeit und Leistung der Modelle zu maximieren.

Zusätzlich wird empfohlen, zusätzliche Datenquellen, wie zum Beispiel Wetter- und Betriebsdaten, zu integrieren, um die Vorhersagegenauigkeit weiter zu steigern. Dies könnte insbesondere in variablen Betriebsumgebungen, wie bei Windkraftanlagen, von großer Bedeutung sein. Darüber hinaus wäre die Implementierung interaktiver Dashboards eine nützliche Maßnahme, um Echtzeitinformationen zum Zustand der Anlagen bereitzustellen und die Akzeptanz der Modelle durch Techniker und Betreiber zu fördern. Die in dieser Studie entwickelten Methoden sind nicht nur auf Windkraftanlagen anwendbar, sondern auch auf andere industrielle Sektoren, wie Fertigungsprozesse und energieintensive Industrien, die von vorausschauender Wartung profitieren könnten.

24 7.2 Einschränkungen der Analyse

Trotz der vielversprechenden Ergebnisse gibt es mehrere Einschränkungen, die die Generalisierbarkeit und Aussagekraft dieser Analyse beeinflussen. Die verwendeten Daten stammen aus einem spezifischen SCADA-Datensatz einer einzelnen Windkraftanlage, was die Übertragbarkeit auf andere Anlagentypen oder unterschiedliche Betriebsumgebungen fraglich macht. Wichtige externe Faktoren wie Wetterbedingungen, Turbinendesign oder unterschiedliche Betriebsbedingungen, die potenziell einen Einfluss auf die Modellleistung haben könnten, wurden in dieser Analyse nicht berücksichtigt. Ein weiteres Problem liegt in der unausgeglichene Datenverteilung, die auch bei Verwendung von Resampling-Techniken und ähnlichen Methoden die Modellleistung verzerren kann.

Ein weiteres Problem ergibt sich durch die Anwendung von Resampling-Techniken, bei denen synthetische Daten erzeugt werden, die auf bestehenden Datenpunkten basieren. Diese Techniken interpolieren lediglich bestehende Muster und berücksichtigen keine potenziell neuen, realistischen Fehlerbilder, wodurch wichtige nicht-lineare Zusammenhänge möglicherweise nicht korrekt erfasst werden. Des Weiteren führt die Entfernung von Grenzfällen während des Resamplings zu einem Verlust von kritischen Datenpunkten, die für die Erkennung von seltenen Fehlern wichtig sind. Bei der Anwendung von Modellen wie dem Decision Tree kann dies auch zu einem Rückgang der Präzision und zu einer Erhöhung der falsch-positiven Vorhersagen führen, was in der Praxis unnötige Wartungsmaßnahmen nach sich ziehen könnte.

Die Modelle wurden ausschließlich auf historischen, statischen Daten getestet, wodurch ihre Fähigkeit zur Echtzeitvorhersage nicht validiert wurde. In dynamischen Betriebsumfeldern, in denen etwa Datenlatenz oder sich ändernde Betriebsbedingungen eine Rolle spielen, könnte die Stabilität der Modelle beeinträchtigt werden. Darüber hinaus berücksichtigt die Analyse der Feature-Importance keine komplexen Wechselwirkungen zwischen den Merkmalen, was dazu führen könnte, dass wichtige Zusammenhänge übersehen werden. Diese Einschränkungen weisen auf die Notwendigkeit hin, die Modelle weiter zu entwickeln, um ihre Generalisierbarkeit und Echtzeitfähigkeit zu verbessern und die potenziellen Risiken von Resampling-Techniken zu minimieren.

25 7.3 Verbesserungspotenzial und zukünftige Forschung

Die Ergebnisse dieser Arbeit eröffnen wertvolle Perspektiven für die Weiterentwicklung der prädiktiven Wartung von Windkraftanlagen. Eine wichtige Verbesserung könnte durch die Erweiterung der verfügbaren Datensätze erzielt werden, etwa durch die Integration zusätzlicher Daten, die spezifische Fehlerarten oder Ausfallursachen umfassen. Darüber hinaus könnten Wetterdaten und Betriebsprotokolle berücksichtigt werden, um die Modelle robuster und genauer zu gestalten. Diese zusätzlichen Informationen würden es ermöglichen, verschiedene Fehlertypen gezielt zu adressieren und die Einflussfaktoren besser zu modellieren, was zu einer insgesamt besseren Vorhersagegenauigkeit führen würde.

Die Optimierung der Datenvorbereitung stellt ebenfalls einen entscheidenden Ansatz zur Verbesserung dar. Insbesondere die Balance zwischen Recall und Präzision könnte durch alternative Resampling-Techniken wie adaptives Sampling oder Kombinationen mit Random Under-Sampling weiter optimiert werden. Dies würde dazu beitragen, die Zuverlässigkeit der Vorhersagen zu erhöhen und gleichzeitig unnötige Wartungsmaßnahmen zu vermeiden. Zudem könnten fortgeschrittene Anomalieerkennungsverfahren helfen, die Qualität der synthetischen Daten sicherzustellen und deren Realitätsnähe zu validieren.

Ein iterativer Ansatz zur kontinuierlichen Aktualisierung und Validierung der Modelle mit aktuellen Daten ist ebenfalls empfehlenswert. Dies könnte durch den Einsatz automatisierter ML-Pipelines erfolgen, die kontinuierlich die Datenvorbereitung, Modelltraining und -bewertung durchführen. Diese Pipelines könnten nahtlos in bestehende SCADA-Systeme integriert werden, um Echtzeitvorhersagen zu ermöglichen und langfristig eine hohe Modellstabilität sicherzustellen. Solche automatisierten Prozesse würden die Effizienz und Genauigkeit der prädiktiven Wartungsmodelle weiter steigern und ihre Anwendung in der Praxis erleichtern.

26 8 Fazit

Diese Untersuchung belegt das große Potenzial von maschinellen Lernmodellen wie Random Forest (RF) und XGBoost (XGB) für die prädiktive Wartung von Windkraftanlagen. Die Nutzung von Resampling-Techniken und Hyperparameter-Tuning ermöglichte es, auch seltene Fehler in einem unausgeglichene Datensatz zuverlässig zu identifizieren. Wesentliche Merkmale, wie die Rotordrehzahl und Temperaturen des Schaltschranks sowie des Inverters, spielten eine zentrale Rolle und führten zu einer effektiven Reduktion der Datensatzdimensionen, was sowohl die Effizienz als auch die Interpretierbarkeit der Modelle steigerte. Während der Entscheidungsbaum eine verständliche Interpretierbarkeit bot, schnitten RF und XGBoost hinsichtlich der Vorhersagekraft besser ab.

Die angewandten Resampling-Techniken verbesserten die Vorhersagegenauigkeit, insbesondere in Bezug auf die Minderheitsklasse, was zu einer besseren Fehlererkennung führte. Die optimierten Modelle erzielten hohe F1-Scores, was ihre Leistungsfähigkeit unter verbesserten Bedingungen verdeutlicht. Trotz vielversprechender Ergebnisse sind die Modelle derzeit nur auf historischen SCADA-Daten validiert worden, sodass unklar bleibt, wie sie sich in Echtzeitanwendungen und dynamischen Betriebsumfeldern verhalten würden. Die Möglichkeit von Datenabweichungen und die Reaktion der Modelle auf veränderte Betriebsbedingungen stellen Herausforderungen dar.

Zukünftige Ansätze sollten darauf abzielen, zusätzliche Datenquellen wie Wetter- und Betriebsdaten zu integrieren, um die Genauigkeit der Vorhersagen weiter zu steigern.

Adaptive Lernmethoden und regelmäßige Modellaktualisierungen könnten die Robustheit in Echtzeitszenarien verbessern. Diese Arbeit zeigt, dass datengetriebene Ansätze nicht nur in der Wartung von Windkraftanlagen, sondern auch in anderen industriellen Bereichen großes Potenzial zur Effizienzsteigerung und Kostenreduktion bieten. Langfristig könnten diese Methoden zu einer nachhaltigeren und kostengünstigeren Energieerzeugung beitragen.

Danksagungen

Die Verantwortung für den Inhalt und die wissenschaftliche Integrität dieser Arbeit liegt ausschließlich bei mir. Sämtliche Formulierungen und Entscheidungen basieren auf meiner eigenen Analyse und Interpretation. Für die Erstellung dieser Seminararbeit habe ich jedoch das LLM ChatGPT-4 von OpenAI verwendet, um bei der Lösung von Programmieraufgaben und der Optimierung des Schreibprozesses zu unterstützen. Das Modell half dabei, Python-Code für das Jupyter-Notebook bereitzustellen und trug zur Verbesserung der Textstruktur, der Vermeidung von Wiederholungen sowie der Korrektur grammatikalischer Fehler bei. Alle vom Modell generierten Vorschläge wurden sorgfältig überprüft und an meinen persönlichen Schreibstil angepasst.

Ich habe sichergestellt, dass die Arbeit den akademischen Standards entspricht und mein geistiges Eigentum darstellt, wobei ich stets die Prinzipien der Authentizität und Unabhängigkeit wahre. Bei Bedarf stehe ich gerne zur Verfügung, um meine Entscheidungen und Formulierungen zu erläutern.

Literatur

References

- [1] Wilmott, P. (2023). *Grundkurs Machine Learning*. [Publisher].
- [2] Fischer, K., Steffes, M., Pelka, K., Tegtmeier, B., & Dörenkämper, M. (2021). Humidity in Power Converters of Wind Turbines—Field Conditions and Their Relation with Failures. *Energies*, 14(7), 1919. <https://doi.org/10.3390/en14071919>.
- [3] Potential of Decision Trees in Non-Linear Machine Learning. *Machine Learning Models*. Retrieved from <https://machinelearningmodels.org/the-potential-of-decision-trees-in-non-linear-machine-learning/>
- [4] Singh, A. (2024). Random Forest Algorithm in Machine Learning. *Applied AI Course Blog*. Retrieved from <https://www.appliedaicourse.com/blog/random-forest-algorithm-in-machine-learning/>
- [5] Endemann, C. (2024). XGBoost: Tree-Based Gradient Boosting for Tabular Data. *UW-Madison Data Science Nexus*. Retrieved from <https://uw-madison-datascience.github.io/ML-X-Nexus/Toolbox/Models/XGBoost.html>
- [6] Demirović, E., & Stuckey, P. J. (2021). Optimal Decision Trees for Nonlinear Metrics. *arXiv preprint*, arXiv:2009.06921v2. <https://doi.org/10.48550/arXiv.2009.06921>.